

**ĐH Quốc Gia Thành phố Hồ Chí Minh**  
**Đại học Công nghệ Thông tin**



**~ BÁO CÁO ĐỒ ÁN ~**

# **NLM ALGORITHM FOR IMAGE DENOISING**

**| Giáo viên hướng dẫn |**  
**Đỗ Văn Tiến**

**Tính toán Đa phương tiện – CS232.M21**

*Thành phố Hồ Chí Minh - 2022*

## DANH SÁCH THÀNH VIÊN

STT	Họ tên	MSSV	Gmail
1	Mai Văn Thiên Phước	20521776	20521776@gm.uit.edu.vn
2	Lâm Minh Tuấn	20520843	20520843@gm.uit.edu.vn
3	Phạm Xuân Hoàng	20520519	20520519@gm.uit.edu.vn



# MỤC LỤC

<b>DANH SÁCH THÀNH VIÊN .....</b>	<b>2</b>
<b>MỤC LỤC .....</b>	<b>3</b>
<b>TỔNG QUAN ĐỀ TÀI.....</b>	<b>4</b>
<b>CHƯƠNG I: GIỚI THIỆU .....</b>	<b>4</b>
<b>CHƯƠNG II: THUẬT TOÁN NLM.....</b>	<b>6</b>
<b>CHƯƠNG III: TÍNH CHẤT.....</b>	<b>8</b>
<b>CHƯƠNG IV: THỰC NGHIỆM.....</b>	<b>10</b>
<b>TÀI LIỆU THAM KHẢO .....</b>	<b>13</b>

# TỔNG QUAN ĐỀ TÀI

Đề tài trình bày về một phương pháp khử nhiễu ảnh (image denoising) dựa trên giá trị trung bình phi cục bộ của tất cả các pixel trong hình ảnh, được gọi là trung bình phi cục bộ (Non-local Means), viết tắt là **NLM**.

Phương pháp này dựa trên một nguyên tắc đơn giản: thay thế màu của một pixel bằng trung bình cộng của các màu của các pixel tương tự. Nhưng các pixel tương tự nhất với một pixel nhất định thường không gần nhau. Do đó, rất khó để quét một phần lớn hình ảnh để tìm kiếm tất cả các pixel thực sự giống với pixel mà ta muốn giảm nhiễu. [5]

## CHƯƠNG I: GIỚI THIỆU


Nhu cầu về các phương pháp khôi phục hình ảnh hiệu quả đã phát triển cùng với sự phát triển ồ ạt của hình ảnh kỹ thuật số và các loại phim, thường được sản xuất trong điều kiện kém. Cho dù máy ảnh tốt đến đâu, cải tiến hình ảnh luôn là một nhu cầu cần thiết, đặc biệt trong kỷ nguyên internet hiện nay. Hình ảnh kỹ thuật số thường được mã hóa dưới dạng các giá trị mức xám (ảnh đen trắng) hoặc giá trị màu sắc (ảnh màu). Nếu là một bộ phim, ma trận này có ba chiều, chiều thứ ba tương ứng với thời gian. Mỗi cặp  $(i; u(i))$  trong đó  $u(i)$  là giá trị tại  $i$  được gọi là pixel. Nếu là một bức ảnh màu,  $i$  là một điểm trên ma trận và  $u(i)$  là tổng hợp giá trị của ba màu đỏ, xanh lá cây và xanh lam (RGB).

Nhiễu ảnh là sự biến đổi ngẫu nhiên của thông tin độ sáng hoặc màu sắc trong ảnh được chụp. Đó là sự suy giảm tín hiệu hình ảnh do các nguồn bên ngoài gây ra. Hình ảnh chứa nhiễu có đặc trưng đó chính là khu vực nào càng sáng thì càng có nhiều nhiễu. Chúng ta có thể mô hình hóa một hình ảnh nhiễu như sau:

$$v(i) = u(i) + n(i)$$

Trong đó  $v(i)$  là giá trị quan sát được (hàm hình ảnh),  $u(i)$  là giá trị thực (hàm ảnh gốc) và  $n(i)$  là nhiễu (hàm nhiễu) tại pixel thứ  $i$ . Cách đơn giản nhất để tạo mô hình ảnh hưởng của nhiễu trên ảnh kỹ thuật số là thêm nhiễu Gauss (Gaussian noise)<sup>[9]</sup>.

Nhiễu Gauss là nhiễu thống kê có hàm mật độ xác suất bằng phân phối chuẩn, còn được gọi là phân phối Gauss. Hàm Gauss ngẫu nhiên được thêm vào hàm ảnh gốc để tạo ra nhiễu kiểu này. Trong trường hợp đó,  $n(i)$  là biến độc lập và phân phối đồng nhất (I.I.D). Giá trị Gauss với giá trị trung bình bằng 0 và phương sai  $\sigma^2$ . Độ lớn của nhiễu Gauss phụ thuộc vào độ lệch chuẩn ( $\sigma$ ). Độ lớn này tỉ lệ thuận với độ lệch chuẩn ( $\sigma$ ).



**Hình 1:** Ảnh hưởng của  $\sigma$  trên nhiễu Gauss. [8]

Mục tiêu của việc giảm nhiễu hình ảnh là khử đi hàm nhiễu để mang lại hình ảnh gốc. Mọi phương pháp giảm nhiễu đều dựa trên tham số lọc  $h$ . Tham số này đo lường mức độ bộ lọc được áp dụng vào hình ảnh. Trong hầu hết các phương pháp, tham số  $h$  dựa trên ước lượng của phương sai nhiễu  $\sigma^2$ . Chúng ta có thể mô hình hóa việc giảm nhiễu như sau:

$$n(D_h, u) = u - D_h(u)$$

Trong đó,  $u$  là hình ảnh và  $D_h$  là toán tử giảm nhiễu dựa trên tham số  $h$ .

Thuật toán **NLM** (Non-local Means) được trình bày và phân tích trong đề tài, được xác định như sau:

$$NL[u](x) = \frac{1}{C(x)} \int_{\Omega} e^{-\frac{(G_a * |u(x+.) - u(y+.)|^2)(0)}{h^2}} u(y) dy,$$

Trong đó  $x \in \Omega$ ,  $C(x) = \int_{\Omega} e^{-\frac{(G_a * |u(x+.) - u(y+.)|^2)(0)}{h^2}} dz$  là hằng số chuẩn hóa,  $G_a$  là Gaussian kernel và  $h$  đóng vai trò là một tham số lọc (filtering parameter)<sup>[4]</sup>. Công thức này có nghĩa là giá trị được quy đổi tại  $x$  là giá trị trung bình của tất cả các điểm có vùng lân cận gaussian giống như vùng lân cận của  $x$ . Sự khác biệt chính của thuật toán **NLM** đối với các bộ lọc cục bộ (local filter) hoặc bộ lọc miền tần số (domain filter) là việc sử dụng một cách có hệ thống tất cả các khả năng tự dự đoán mà hình ảnh có thể cung cấp, dựa theo tài liệu [1]. Để có phân tích chi tiết hơn về thuật toán **NLM** và so sánh đầy đủ hơn, tham khảo [2].

## CHƯƠNG II: THUẬT TOÁN NLM

Cho một ảnh nhiễu rời rạc  $v = \{v(i) \mid i \in I\}$ , giá trị ước tính  $NL[v](i)$ , đối với một pixel thứ  $i$ , được tính là giá trị trung bình có trọng số của tất cả các pixel trong hình ảnh,

$$NL[v](i) = \sum_{j \in I} w(i, j) v(j),$$

Trong đó họ trọng số  $\{w(i, j)\}_j$  phụ thuộc vào sự giống nhau giữa các pixel  $i$  và  $j$ , và thỏa mãn các điều kiện thông thường  $0 \leq w(i, j) \leq 1$  và  $\sum_j w(i, j) = 1$ .

Sự giống nhau giữa hai pixel  $i$  và  $j$  phụ thuộc vào sự giống nhau của các vector mức xám<sup>[3]</sup> (grey level)  $v(N_i)$  và  $v(N_j)$ , trong đó  $N_k$  biểu thị vùng lân cận hình vuông có kích thước cố định và được căn giữa tại pixel  $k$ .

Sự tương tự này được đo dưới dạng một hàm giảm dần của khoảng cách Euclide có trọng số  $\|v(N_i) - v(N_j)\|_{2,a}^2$ , trong đó  $a > 0$  là độ lệch chuẩn của Gaussian

kernel<sup>[10]</sup>. Việc áp dụng khoảng cách Euclide đối với các biến nhiều lân cận làm tăng sự cân bằng

$$E \|v(N_i) - v(N_j)\|_{2,a}^2 = \|v(N_i) - v(N_j)\|_{2,a}^2 + 2\sigma^2$$

Sự cân bằng này cho thấy tính sức mạnh của thuật toán vì khoảng cách Euclid bảo tồn thứ tự tương đồng giữa các pixel.


Các pixel có vùng lân cận mức xám (grey level) tương tự với  $v(N_i)$  có trọng số lớn hơn ở mức trung bình, xem hình 2. Các trọng số này được định nghĩa là,

$$w(i, j) = \frac{1}{Z(i)} e^{-\frac{\|v(N_i) - v(N_j)\|_{2,a}^2}{h^2}},$$

Trong đó  $Z(i)$  là hằng số chuẩn hóa


$$Z(i) = \sum_j e^{-\frac{\|v(N_i) - v(N_j)\|_{2,a}^2}{h^2}}$$

Và tham số  $h$  đóng vai trò là mức độ lọc (degree of filtering).



**Hình 2:** Các vùng lân cận pixel tương tự cho trọng số lớn,  $w(p, q1)$  và  $w(p, q2)$ , trong khi các vùng lân cận khác nhau cho trọng số nhỏ  $w(p, q3)$

**NLM** không chỉ so sánh mức xám (grey level) ở một điểm đơn lẻ mà cả cấu trúc hình học trong toàn bộ vùng lân cận. Hình 2 minh họa thực tế này, pixel  $q_3$  có cùng giá trị mức xám của pixel  $p$ , nhưng các vùng lân cận khác nhau nhiều và do đó trọng số  $w(p, q_3)$  gần bằng 0.



**Hình 3:** *Hiện thị phân bố trọng số NLM được sử dụng để ước tính các pixel trung tâm của mọi hình ảnh. Các trọng số đi từ 1 (trắng) đến 0 (đen).*

### CHƯƠNG III: TÍNH CHẤT

Theo các giả định, với mỗi pixel  $i$ , thuật toán NLM hội tụ với kỳ vọng có điều kiện xét trên một vùng lân cận của nó. Trong trường hợp này, điều kiện ổn định có nghĩa là khi kích thước của hình ảnh lớn lên, chúng ta có thể tìm thấy nhiều bản vá(patch) tương tự cho tất cả các chi tiết của hình ảnh.

Gọi  $V$  là một trường ngẫu nhiên và giả sử rằng ảnh nhiễu  $v$  là một thực nghiệm của  $V$ . Gọi  $Z$  biểu diễn tập hợp các biến ngẫu nhiên  $Z_i = \{Y_i, X_i\}$ , trong đó  $Y_i = V(i)$  có giá trị thực và  $X_i = V(N_i \setminus \{i\})$  có giá trị  $\mathbb{R}^p$ . NLM là một ước lượng cho kỳ vọng có điều kiện  $r(i) = E[Y_i | X_i = v(N_i \setminus \{i\})]$ .

**Định lý (Kỳ vọng có điều kiện)** Cho  $Z = \{V(i), V(N_i \setminus \{i\})\}$  với  $i = 1, 2, \dots$  là một quá trình phân phối hỗn hợp (mixing process), và đồng cũng là quá trình



dừng ngặt (strictly stationary). Gọi  $NL_n$  là biểu diễn của thuật toán NLM được áp dụng cho dãy  $Z_n = \{V(i), V(N_i \setminus \{i\})\}_{i=1}^n$ , khi đó:

$$|NL_n(j) - r(j)| \rightarrow 0 \quad a.s$$

Với  $j \in \{1, 2, \dots, n\}$ .

Tuyên bố đầy đủ về giả thuyết của định lý và cách chứng minh của nó có thể được tìm thấy trong một khuôn khổ tổng quát hơn trong [6]. Định lý này cho chúng ta minh bạch rằng NLM thích hợp chỉnh sửa ảnh nhiễu hơn là cố gắng tách nhiễu (oscillatory) khỏi ảnh thực.

Trong trường hợp giả định: mô hình nhiễu trắng (White noise)<sup>[9]</sup> được cộng tính(additive), kết quả tiếp theo cho thấy kỳ vọng có điều kiện là hàm của  $V(N_i \setminus \{i\})$ , làm giảm thiểu sai số bình phương trung bình (mean square error) với ảnh thực  $u$ .

**Định lý** Gọi  $V$ ,  $U$ ,  $N$  là các trường ngẫu nhiên trên  $I$  sao cho  $V = U + N$ , trong đó  $N$  là các tín hiệu nhiễu trắng độc lập. Những trạng thái này sẽ được cố định sau đó:

- (i)  $E[V(i) | X_i = x] = E[U(i) | X_i = x] \forall i \in I \&\& x \in \mathbb{R}^p$
- (ii) Biến ngẫu nhiên kỳ vọng  $E[U(i) | V(N_i \setminus \{i\})]$  là hàm của  $V(N_i \setminus \{i\})$  để cực tiểu hóa sai số bình phương trung bình (minimize the mean square error).


$$\min_g E[U(i) - g(V(N_i \setminus \{i\}))]^2$$

Các kết quả lý thuyết về độ tối ưu tương tự đã thu được trong [7] và được dùng trong khử nhiễu ảnh nhị phân.

## CHƯƠNG IV: THỰC NGHIỆM

Thuật toán NLM chọn cho mỗi pixel một thông số trung bình khác nhau được điều chỉnh cho phù hợp với hình ảnh. Đối với pixel  $i$ , chúng ta chú ý đến vùng lân cận của  $i$  và toàn bộ pixel trong hình ảnh. Sự giống nhau giữa những pixel được đo dưới dạng một hàm giảm của khoảng cách Euclide của các cửa sổ tương tự. Bởi vì sự phân rã của kernel theo cấp số nhân, khoảng cách Euclide càng lớn thì trọng số càng giảm về 0, hoạt động như một ngưỡng tự động. Sự phân rã của hàm mũ và sự phân rã của trọng số được điều khiển bởi tham số  $h$ . Để đảm bảo rằng chỉ các pixel ở vùng lân cận có trọng số lớn,  $h$  phải được lấy từ bậc của  $\sigma$ .


Do bản chất của thuật toán, trường hợp thuận lợi nhất cho NLM là trường hợp tuần hoàn. Trong tình huống này, đối với mỗi pixel  $i$  của ảnh, ta có thể tìm thấy một tập hợp lớn các mẫu có cấu hình rất giống nhau, dẫn đến giảm nhiễu và bảo toàn ảnh gốc, xem Hình 4 là một ví dụ.



**Hình 4:** Thực nghiệm NLM với 1 ảnh cận tuần hoàn. Trái: Hình ảnh nhiễu với độ lệch chuẩn 30. Bên phải: Ảnh được phục hồi bởi NLM

Một trường hợp lý tưởng khác phù hợp cho việc áp dụng thuật toán NLM là trường hợp kết cấu. Hình ảnh kết cấu có độ dư thừa lớn. Đối với một cấu hình cố định, nhiều mẫu tương tự có thể được tìm thấy trong hình ảnh. Trong Hình 5, người ta có thể thấy một ví dụ với kết cấu Brodatz. Fourier Transform của các hình ảnh bị nhiễu và được khôi phục, cho thấy khả năng của thuật toán bảo toàn các đặc điểm chính ngay cả trong trường hợp tần số cao.


NLM không chỉ khôi phục hình ảnh tuần hoàn hoặc kết cấu, mà còn dùng được với cả hình ảnh tự nhiên. Ví dụ trong một vùng phẳng, người ta có thể tìm thấy nhiều pixel nằm trong cùng một vùng và các cấu hình tương tự. Ở một cạnh thẳng hoặc cong, một dòng pixel hoàn chỉnh có cấu hình tương tự được tìm thấy. Ngoài ra, sự dư thừa của các hình ảnh tự nhiên cho phép chúng ta tìm thấy nhiều cấu hình tương tự ở các pixel ở xa. Hình 6 và 7 cho thấy hai ví dụ về hai hình ảnh xử lý tiêu chuẩn nổi tiếng.



**Hình 5:** Thực nghiệm NLM với hình ảnh kết cấu Brodatz. Trái: Hình ảnh nhiễu với độ lệch chuẩn 30. Bên phải: Ảnh được phục hồi bởi NLM



**Hình 6:** Thực nghiệm NLM với một hình ảnh tự nhiên. Trên: Hình ảnh nhiễu với độ lệch chuẩn 20. Bên dưới: Hình ảnh đã được khôi phục



**Hình 7:** Thực nghiệm NLM với một hình ảnh tự nhiên. Trái: Hình ảnh nhiễu với độ lệch chuẩn 35. Bên phải: Hình ảnh đã được khôi phục.

Thuật toán tương tự cũng áp dụng cho việc khôi phục ảnh và phim màu, xem Hình 8.



**Hình 8:** Thực nghiệm NLM với hình ảnh màu. Trái: Hình ảnh nhiễu với độ lệch chuẩn 15 trong mọi thành phần màu. Phải: Hình ảnh đã được khôi phục.

# TÀI LIỆU THAM KHẢO

- [1]. A. Efros and T. Leung. Texture Synthesis by Non-parametric Sampling.
- [2]. A. Buades, B. Coll, J. Morel. On image denoising method.
- [3]. M. Nixon, A. Aguado. Feature Extraction & Image Processing for Computer Vision. Chapter 13 - Appendix 4: Color images.
- [4]. Manisha, S. Dahiya. Comparative Analysis of Different Image Enhancement Techniques.
- [5]. A. Buades, B. Coll, J. Morel. Non-Local Means Denoising.
- [6]. G. Roussas. Nonparametric regression estimation under mixing conditions. Stochastic processes and their applications
- [7]. E. Ordentlich, G. Seroussi, M. Verdu, T. Weiss- man. A discrete universal denoiser and its application to binary images.
- [8]. Anisha Swain. Noise in Digital Image Processing (Medium.com)
- [9]. A. Boyat, B. Joshi. A review paper: Noise models in Digital image processing.
- [10]. M. Chung. The Gaussian Kernel (pages.stat.wisc.edu)